

# Unmixing Guided Unsupervised Network for RGB Spectral Super-Resolution

任启

## 摘要

本项目旨在复现一种解混引导的无监督网络，用于光谱超分辨率任务。与传统的光谱超分算法不同，该方法不依赖于成对的训练数据，而是利用任意高光谱图像作为引导图像，实现无监督的高光谱重建。然而，在复现算法过程中，我们发现其在光谱邻近关系的考虑方面存在一定的不足。为了克服这些不足，我们提出了改进方案。首先，我们设计了新的编码器和重构模块，以更好地捕捉光谱信息并保持空间一致性。通过多尺度特征集成，我们能够降低计算复杂度，从而提高算法的效率。其次，我们构建了新的损失函数，利用光谱-空间先验生成粗粒度的高光谱图像，并通过细化处理提升重建质量。最后，我们在下游的分类任务中验证了我们改进算法的优势。通过优化和改进，我们的复现算法在光谱超分辨率任务中取得了突破性进展。然而，我们也认识到仍有改进的空间，特别是在光谱邻近关系的处理上。未来的研究可以进一步探索融合多源数据的特性，利用不同类型卫星所拍摄的遥感图像，以实现更高效的光谱重建。这将进一步提升光谱超分辨率任务的性能和应用范围。

**关键词：**无监督光谱超分；光谱解混；对抗学习

## 1 引言

高光谱图像(HSI)包含丰富的光谱信息，因此可应用于少数领域，如场景分类 [1–3]，目标检测 [4, 5]以及分割 [6]。由于硬件的限制，难以同时具有高空间分辨率和高光谱分辨率的HSI，这就导致了一个新的研究方向：高光谱超分。高光谱超分旨在从低分辨率的高光谱或者高分辨率的RGB图像中生成高分辨率的HSI。根据输入的格式，现有方法大致可分为三类：HSI的空间超分辨率、RGB图像的光谱超分辨率以及基于多光谱和RGB融合的超分辨率。

HSI的空间超分辨率是通过低分辨率的高光谱的空间信息重构获取高空间分辨率的HSI。现有方法大多基于光谱基函数 [7]，稀疏字典表示学习 [8]，最大后验 [9]和深度学习等。空间光谱先验和一致性正则化属于共有的研究热点。比如，王等人设计出一个正则化网络来加强空间-光谱相关性 [10]。此外，还有许多研究工作利用人工设计的先验指导空间信息的恢复。

光谱超分算法旨在从高分辨率RGB图像重构光谱通道生成高空间分辨率的HSI。基于退化公式，大多数传统方法探索RGB图像与HSI之间的映射关系。比如，Parmar等人利用图像的稀疏行，共同重构空间光谱特征 [11]。Arad等人创建HSI的稀疏字典，通过高光谱先验知识

获得RGB图像投影 [12]。近年来，深度学习方法，特别是卷积神经网络(Convolutional neural networks, CNNs)，在光谱超分辨率任务中表现出良好的性能。例如，利用光谱响应函数对具有光谱相关性的波段进行分组。基于隐式神经表征的网络被提出模拟成像噪声和目标光谱的多次反射。Transformer应用于光谱超分辨率，以此捕获自相似先验和远程依赖。此外，一些研究人员将先验知识纳入神经网络，为了避免手动设计参数。

基于多光谱和RGB融合的超分辨率方法同样被广泛应用，主要通过低分辨率的HSI和高分辨率的多光谱/RGB图像。首先提出了矩阵分解、张量分解和贝叶斯等传统方法。然后，基于深度学习的方法逐渐成为主流。许多模型引导网络被提出以端到端方式优化手工提取的先验知识。最近，无监督算法被提出用于解决标签获取问题。然而，通常无法获得配对的HSI-RGB图像，导致基于融合的超分辨率难以实现。

虽然目前已提出许多研究方法，但光谱超分的挑战之一是在训练过程中同时需要配对高和低分辨率图像，这使得高光谱超分任务需以监督的方式进行。然而，配对的HSI和RGB图像数据难以同时获取，这大大增加了监督网络训练的难度。因此，许多研究人员试图通过未配对的书记设计出无监督光谱超分辨率网络。

复现论文主要根据HSI的特点，提出一种解混引导无监督HSI超分辨率网络(UnGUN) [13]，该网络借助引导HSI和光谱响应函数实现光谱超分。其中光谱解混主要是指重构图像中纯物质的光谱（即端元）和对应物质在每个像元中的比例（即丰度）。在HSI的众多应用领域中，如遥感中，不同场景对应的物质分布通常具有相似行。因此，不同场景中的端元往往具有相似性，这表明其他场景的端元可以帮助重建超分辨率图像的端元。即使现有图像的地面对象与超分辨率图像不对应，引导图像中包含的整体光谱分布信息仍然可以为超分辨率图像提供先验信息。此外，由于光谱解混可以完全分离和提取输入的空间光谱信息，这有利于后续的特征融合，基于此，设计出基于引导图像光谱解混的光谱超分辨率网络。具体而言，UnGUN具有两个输入：需要光谱超分的RGB图像和引导HSI。值得注意的是，RGB和引导图像无需配对。此外，利用光谱响应函数约束重构HSI与输入RGB图像之间的关系，以此保证超分辨率效果。

复现论文提出的UnGUN以生成对抗的方式进行优化，其中生成器主要由三个自编码器分支组成：两个解混分支和一个重建分支。解混分支分布实现引导HSI和RGB图像的分解。经过光谱解混之后，获取到对应的端元和丰度，主要包含光谱和空间信息。重建分支进一步利用RGB解混分支的丰度和高光谱解混分支的端元初始化HSI。然后对粗粒度HSI进行细化，得到最终的HSI。因此，通过重建分支将HSI的光谱特征与RGB图像的空间信息进行整合。此外，还设计了一个鉴别器，以保证重建图像的分布与真实引导HSI数据相似。一般来说，引导图像具有两种作用：指导HSI的初始化和提高发生器的生成能力。

## 2 相关工作

### 2.1 高光谱图像获取

传统的HSI系统通常采用光谱仪在空间或光谱维度上对场景进行扫描。目前的HSI成像技术，如推扫扫描仪、数字阵列扫描仪和时间序列扫描仪，已广泛应用于探测、遥感、医学成像和环境监测等领域。然而，这些扫描成像过程耗时且仅适用于静态对象。在对时间敏感的应用和存在物体与环境相对运动的情况下，使用时间序列HSI成像可能导致空间失衡和光谱

失真。此外，这些仪器设备体积庞大，不便携带。最近，为了克服上述限制，提出了单快门压缩成像（SCI）系统，它通过拍摄HSI将三维HSI压缩为二维测量值。其中，以编码孔径快照光谱成像为代表的SCI方法显示出巨大的潜力。然而，SCI系统目前仍不太适用于日常应用，并且成本昂贵。因此，HSI光谱重构具有重要的研究价值和意义。

## 2.2 单张RGB图像光谱恢复

目前，由于CNN的方法性能出色，一种深度光谱差分网络被提出，用于解决从RGB重建HSI的复杂问题。Xiong等人提出HSCNN网络，利用RGB图像和压缩测量重建HSI [14]。而Shi等人在HSICNN的基础上，引入残差和密集连接，构建自适应残差块，进一步提升重建性能 [15]。Zhang等人设计出像素感知的深层函数混合网络，学习不同感受野的大小，从RGB建模到HSI [16]。Galilian等人利用密集连接的U-Net网络对HSI重构 [17]。TSA-Net采用空谱自注意力，实现HSI波段恢复。上述基于CNN的方法虽然具有出色的优势，但是受限于捕获全局相似性和远程依赖关系，不利于光谱信息的利用 [18]。

## 3 本文方法

### 3.1 本文方法概述

在本文复现模型中，输入为RGB图像 $X \in \mathbb{R}^{H \times W \times 3}$ 和引导HSI $Y \in \mathbb{R}^{h \times w \times c}$ 。 $H$ 和 $W$ 分别表示为 $X$ 的长和宽，而 $h$ ， $w$ 和 $C \gg 3$ 分别表示为 $Y$ 的长、宽和波段数。论文目标是重建 $X$ 的光谱，得到具有高光谱分辨率的图像 $Z \in \mathbb{R}^{H \times W \times C}$ 。

大多数光谱超分辨率算法通过Ground truth监督。然而，在现实世界中，具有HSI分辨率的标签往往是不可用的，这将导致算法的失败。因此，近年来提出了许多无监督算法。与有监督算法相比，无监督算法在训练过程中由于缺乏真实数据，重建的图像往往存在颜色偏差和纹理失真。为了解决这个问题，作者提出了一个由引导HSI指导的无监督光谱重建模型。复现算法受到光谱分解的启发，如图1所示，因此，UnGUN主要由三个分支构成，包括两个解混分支和一个重建分支。整体架构如图2所示。

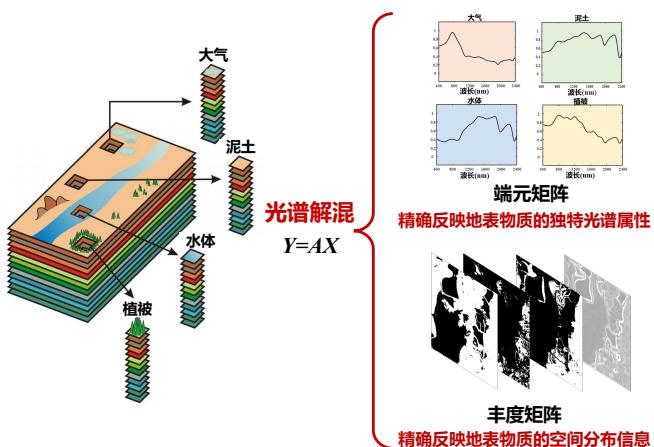


图 1. 光谱分解示意图

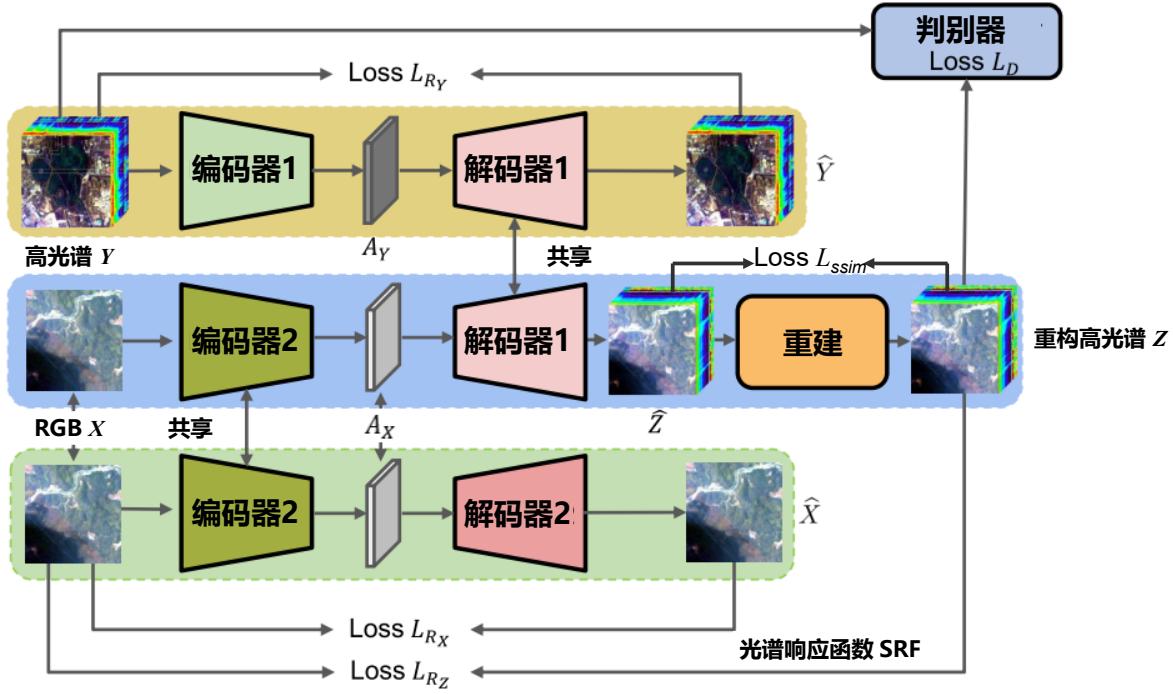


图 2. UnGUN方法示意图

首先，将RGB图像和引导HSI分别进行光谱解混，得到对应的丰度和端元。其中，丰度包含空间信息，端元包含光谱信息。RGB图像和引导HSI通过相同结构进行解混：

$$X = A_X \cdot M_X \quad (1)$$

$$Y = A_Y \cdot M_Y \quad (2)$$

其中， $M_X \in \mathbb{R}^{L \times 3}$  和  $M_Y \in \mathbb{R}^{L \times C}$  分别是RGB图像和引导HSI的端元， $A_X \in \mathbb{R}^{HW \times L}$  和  $A_Y \in \mathbb{R}^{hw \times L}$  分别是丰度。 $L$  表示为光谱端元数。

对于光谱重建，利用RGB图像的丰度和引导HSI的端元重建生成粗糙的HSI  $\hat{Z}$ ，如等式(3)。基于不同HSI数据集对应的端元相似性，尝试在  $M_Y$  的引导下初始化光谱信息。因为  $M_Y$  包含真实光谱分布的信息，所以即使引导图像中不存在材料，同样可以引导重建分支生成真实分布的光谱特征。以这种方式，在HSI解混分支的帮助下，重建分支可以对RGB图像中包含的端元矩阵进行优化，从而保证重建HSI光谱特征的准确性。

$$\hat{Z} = A_X \cdot M_Y \quad (3)$$

最后，通过调节模块，粗级HSI  $\hat{Z}$  细化为最终HSI  $Z$ ，如等式(4)。

$$Z = Adj(\hat{Z}) \quad (4)$$

此外，为了进一步保证重建图像的真实性，作者设计出一个鉴别器来识别  $Z$  和引导图像，最终确保重建图像接近真实HSI。具体而言，当RGB图像存在引导图像中不存在的地物时，后续的调节模块在识别损失和重建损失的约束下，会生成更合理的端元分布。

### 3.2 解混分支

三个分支共享相同的自动编码器解混结构，如图所示。经过编码器后，输入图像分解为丰度。由于编码器的最后一层为Softmax，因此生成的丰度满足ANC和ASC。然后，解码器作为具有潜在丰度的输入图像的端元。

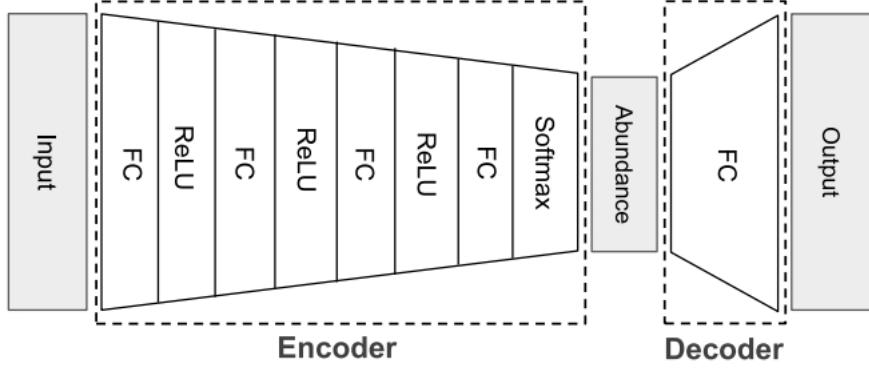


图 3. 光谱解混结构。编码器是绿色框，解码器是粉色框

#### 3.2.1 HSI解混分支

HSI解混分支划分为两部分，编码器1： $En_1 \in \mathbb{R}^{hw \times C} \rightarrow \mathbb{R}^{hw \times L}$ , 将引导HSI映射到潜在表征 $A_Y$ ；解码器1： $De_1 \in \mathbb{R}^{hw \times L} \rightarrow \mathbb{R}^{hw \times C}$ ，以 $A_Y$ 作为端元 $M_Y$ 重建输入HSI。HSI解混分支可表示为：

$$A_Y = En_1(Y) \quad (5)$$

$$\hat{Y} = De_1(A_Y) \quad (6)$$

为了保证重建效果，我们利用L2损耗最小化 $Y$ 和 $\hat{Y}$ 之间的逐像素误差，如等式 (7) 所示：

$$L_{RY} = \|Y - \hat{Y}\|_2 \quad (7)$$

此外，由于每个像素通常仅包含几个纯光谱，在真实世界中，丰度应该是稀疏的。因此，我们采用基于丰度和一个微小常数 $\epsilon$ 之间的KL散度的稀疏性损失作为等式 (8)。

$$\begin{aligned} L_{SY} &= \sum_{j=1}^{hw} KL(\epsilon \| A_{Y_j}) \\ &= \sum_{j=1}^{hw} \left( \epsilon \log \frac{\epsilon}{A_{Y_j}} + (1 - \epsilon) \log \frac{1 - \epsilon}{1 - A_{Y_j}} \right) \end{aligned} \quad (8)$$

$KL$  is the standard divergence:

$$KL(p \| q) = p \log \frac{p}{q} + (1 - p) \log \frac{1 - p}{1 - q} \quad (9)$$

因此，HSI解混支路的总损失为等式 (7-8) 的加权和。 $\alpha_Y$ 和 $\beta_Y$ 是权重。

$$L_Y = \alpha_Y L_{RY} + \beta_Y L_{SY} \quad (10)$$

值得注意的是，在实验中，HSI解混分支的解码器，即光谱端元矩阵，是通过VCA方法从Salinas数据集初始化的。

### 3.2.2 RGB解混分支

与HSI解混分支一致，RGB解混分支同样由两部分构成。编码器2:  $En_2 \in \mathbb{R}^{HW \times 3} \rightarrow \mathbb{R}^{HW \times L}$ ，映射RGB图像到潜在表示  $A_X$ ，并且解码器2:  $De_2 \in \mathbb{R}^{HW \times L} \rightarrow \mathbb{R}^{HW \times 3}$ ，以  $A_X$  为端元  $M_X$  重建输入的RGB图像。RGB解混分支可表示为：

$$A_X = En_2(X) \quad (11)$$

$$\hat{X} = De_2(A_X) \quad (12)$$

同理，重构损失和稀疏度损失用等式 (13-14) 表示：

$$L_{R_X} = \|X - \hat{X}\|_2 \quad (13)$$

$$\begin{aligned} L_{S_X} &= \sum_{i=1}^{HW} KL(\epsilon \| A_{X_i}) \\ &= \sum_{i=1}^{HW} \left( \epsilon \log \frac{\epsilon}{A_{X_j}} + (1-\epsilon) \log \frac{1-\epsilon}{1-A_{X_j}} \right) \end{aligned} \quad (14)$$

然后，RGB解混分支的总损失是等式 (13-14) 的加权和。

$$L_X = \alpha_X L_{R_X} + \beta_X L_{S_X} \quad (15)$$

### 3.3 重构分支

在这个分支中，利用RGB图像的空间信息和引导HSI的光谱信息来重建高分辨率HSI  $X$ 。粗HSI  $\hat{X}$  是先用解混结构生成。重建分支的编码器与RGB解混分支共享参数。编码器2:  $En_2 \in \mathbb{R}^{HW \times 3} \rightarrow \mathbb{R}^{HW \times L}$ 。编码器2之后，将RGB分解为包含纹理特征的丰度  $A_X$ 。然后，通过解码器获取粗HSI  $\hat{X}$ ，该解码器与HSI解混分支  $De_1$  共享参数。由于解码器表示Y的光谱端元，在引导HSI的作用下，生成初始化HSI  $\hat{Z}$ 。粗HSI的重建可表示为

$$A_X = En_2(X) \quad (16)$$

$$\hat{Z} = De_1(A_X) \quad (17)$$

在引导图像的帮助下， $\hat{Z}$  获取真实HSI的光谱信息。但是，实际HSI的光谱分布与  $\hat{Z}$  之间仍有差异。因此，设计出一个调整模块细化纹理和颜色信息。为了获取更加准确的HSI，将  $\hat{Z}$  输入重建模块  $Adj \in \mathbb{R}^{HW \times C} \rightarrow \mathbb{R}^{HW \times C}$ 。然后，重建细化HSI  $Z$ :

$$Z = Adj(\hat{Z}) \quad (18)$$

对于重建分支，采用两个损失函数：重建损失  $L_{R_Z}$  和TV损失  $L_{TV}$ 。 $Z$  为  $X$  光谱超分所得的HSI。因此， $Z$  经过光谱响应函数生成的RGB图像，与  $X$  一致。因此，采用L2损失最小化  $X$  与  $R \cdot Z$ ，如等式 (19) 所示。其中  $R$  是谱响应函数。

$$L_{R_Z} = \|X - R \cdot Z\|_2 \quad (19)$$

HSI的另一个物理特性是，对于一个像素，相邻通道之间的差异不会太大。基于上述性质，引入总变差损失 $L_{TV}$ ：

$$L_{TV} = \sum_{i=1}^{HW} \sum_{j=1}^{C-1} (Z_{i,j} - Z_{i,j+1}) \quad (20)$$

则重建分支的总损失为等式 (19-20)。 $\alpha_Z$ 和 $\beta_Z$ 是权重系数。

$$L_Z = \alpha_Z L_{RZ} + \beta_Z L_{TV} \quad (21)$$

### 3.4 判别器

为了使超分辨HSIZ更逼真，设计了鉴别器，使 $Z$ 的分布更接近真实的HSIY。鉴别器的目的是迫使最终的高分辨率HSIZ的分布类似于真实的高光谱图像。生成器的损失函数(包括HSI分解支路、RGB分解支路和重构支路)表示为等式 (22)：

$$L_G = L_g + L \quad (22)$$

$$L_g = BCE(D(Z), 1) \quad (23)$$

$$L = \alpha L_X + \beta L_Y + \lambda L_Z \quad (24)$$

$BCE(\cdot)$ 是二值交叉熵损失， $D(\cdot)$ 是判别器， $\alpha$ ， $\beta$ 和 $\gamma$ 是超参数，用于平衡不同损失。

判别器的损失函数是：

$$L_D = BCE(D(Z), 0) + BCE(D(Y), 1) \quad (25)$$

在训练过程中，交替优化生成器和鉴别器，最终达到收敛。此外，采用梯度裁剪的方法来保证对抗学习的稳定性，避免了梯度爆炸的问题。

## 4 复现细节

### 4.1 与已有开源代码对比

本文复现代码参考已开源代码。作者未提供论文中数据集裁剪的代码，本人完成对数据集的裁剪，具体代码如下：

```

1 import numpy as np
2 import scipy.io as sio
3 import h5py
4 # -*- coding: utf-8 -*-
5 # 根据实际数据文件路径加载高光谱数据
6 # data = sio.loadmat('guidance_data/ICVL/Salinas_corrected_31.mat')
7 # ['guidance_image']
8 # data = sio.loadmat('data/DFC2018
# Houston/HoustonU.mat')[['guidance_image']]
```

```

9  data = h5py.File('data/DFC2018
10 # Houston/HoustonU.mat')[ 'houstonU' ][:]
11
12 # 定义裁剪区域的大小和步长
13 patch_size = 128 # 裁剪区域的大小
14 stride = 64 # 步长
15
16 # 获取高光谱数据的形状
17 data_shape = data.shape
18
19 def Im2Patch(img, win, stride=1):
20     k = 0
21     endc = img.shape[0]
22     endw = img.shape[1]
23     endh = img.shape[2]
24     patch = img[:, 0:endw-win+0+1:stride, 0:endh-win+0+1:stride]
25     TotalPatNum = patch.shape[1] * patch.shape[2]
26     Y = np.zeros([endc, win*win, TotalPatNum], np.float32)
27     for i in range(win):
28         for j in range(win):
29             patch =
30                 img[:, i:endw-win+i+1:stride, j:endh-win+j+1:stride]
31             Y[:, k, :] = np.array(patch[:]).reshape(endc,
32                                         TotalPatNum)
33             k = k + 1
34     return Y.reshape([endc, win, win, TotalPatNum])
35
36 # creat patches
37 patches_hyper = Im2Patch(data, patch_size, stride)
38 patch_num = 1
39 # add : data 重组patches
40 for j in range(patches_hyper.shape[3]):
41     print("generate sample #%d" % patch_num)
42     cropped_data = patches_hyper[:, :, :, j]
43     # 输出裁剪结果的形状
44     print("第" + str(patch_num) + "块裁剪区域")
45     print("Cropped data shape:", cropped_data.shape)
46     if patch_num < 200:

```

```

45         sio.savemat('data/DFC2018_Houston/traindata/HoustonU_+' +
46             str(patch_num) + '.mat', {'rad': cropped_data})
47     else:
48         sio.savemat('data/DFC2018_Houston/testdata/HoustonU_+' +
             str(patch_num) + '.mat', {'rad': cropped_data})
patch_num += 1

```

## 4.2 实验环境搭建

本地使用11th Gen Intel(R) Core(TM) i7-11700、32G内存的电脑调试代码，并使用服务器A40训练和测试模型，如图4所示，主要以pytorch框架。实验中使用引导高光谱做光谱下采样，使得与目标HSI通道一致。RGB图像由SRF与对应的HSI生成。在训练过程中，RGB图像和引导HSI作为输入，对应的HSI无需输入网络中。

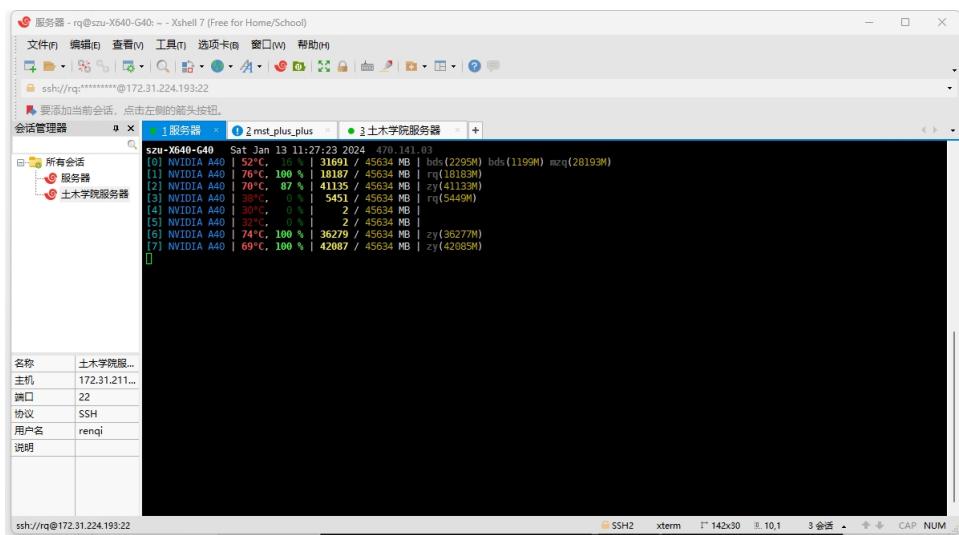


图 4. 操作界面示意

## 4.3 创新点

考虑到复现算法在HSI光谱邻近关系方面存在不足。因此，针对上述不足，我们设计出新的编码器和重构模块，并构建损失函数，重建光谱-空间先验，生成粗粒度HSI。

其中一项改进是对编码器进行多尺度特征集成，集中降低计算复杂度，如图5所示。编码器模块进行多尺度特征集成，主要由不同大小的卷积层、BN层、池化层和激活函数构成[19]。一方面，充分利用多尺度特征提取局部空间信息；另一方面，对融合特征进行一维卷积降维，提高计算效率和后续的特征提取。

超分是实现三到多映射的病态转换。由于在这个过程中存在许多不确定性，因此放大波段之间的结构相似性和上下文关系至关重要。然而，以往的超分方法要么关注空间关系，要么增强全通道关注，从而阻碍了网络的表征能力。另外一处改进灵感来源于MAE，如图6所示，将输入图像分割成小块，并随机屏蔽小块，以重建缺失像素和光谱特征，来减少数据冗余。

最后，构建一个新的损失函数，用于重建粗粒度的光谱-空间先验HSI，并对其进行细化出来，如图7所示。浅层HSI中随机像素的光谱曲线波动较大，但经过重建模块后，曲线变得更平滑。同时，由于目前重建出来的图像仅能依靠评价指标来区分。于是，我们进一步将原始代码重建出来的结果和改进后代码重建出来的结果，应用于下游分类任务中，以此验证方法性能。

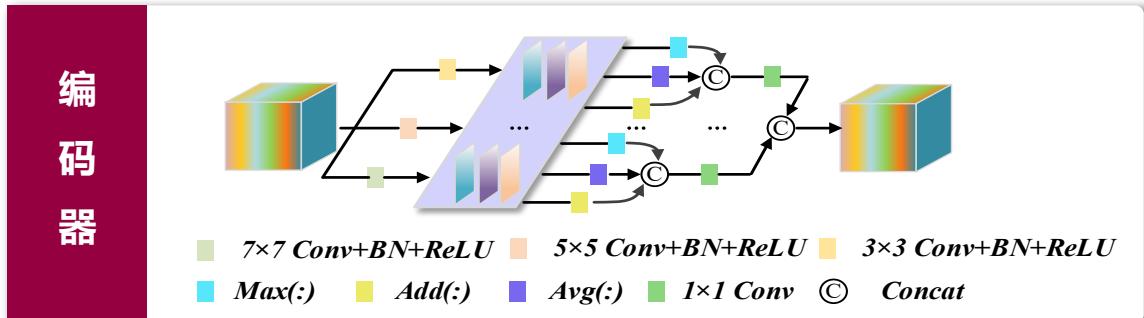


图 5. 改进编码器的结构

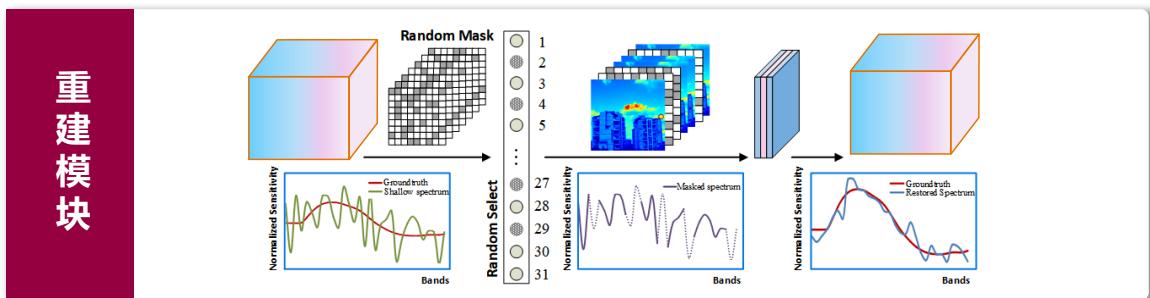


图 6. 改进重建模块的结构

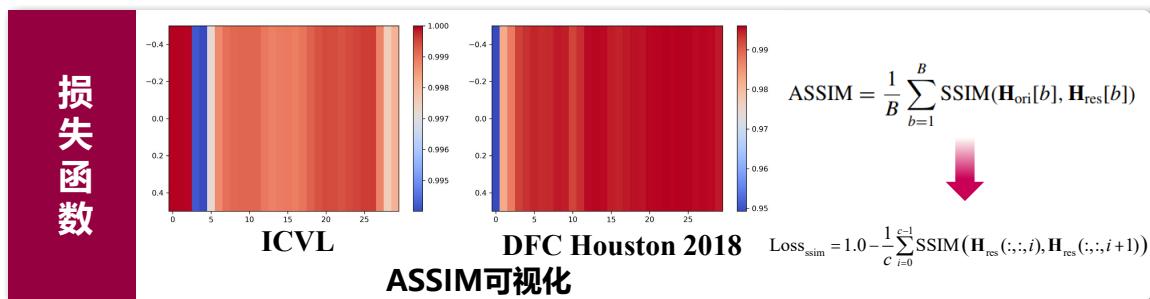


图 7. 改进损失函数的结构

## 5 实验结果分析

我们在ICVL和DFC2018 Houston两个数据集上进行了对比实验，比较了原文结果、复现结果和改进结果，具体结果如表1所示。尽管复现结果相对于原文结果稍逊一筹，但通过对网络的改进，我们成功地提升了重建效果。我们在ICVL数据集上选择了第1到3个通道，在DFC2018 Houston数据集上选择了第15、23和30通道进行对比分析，如图8和9。为了更直观地展示结

果，我们在图10中可视化了Ground Truth、UnGUN和UnGUN(新)的光谱曲线，观察到改进方法更好地符合Ground Truth的光谱分布。

然而，仅仅依靠评价指标来判别重建效果是不充分的，尤其考虑到DFC2018 Houston是一个遥感数据集。因此，我们将我们的算法应用于这个数据集，并在下游的分类任务中评估其实际表现。我们选择了传统的支持向量机算法作为分类器。令人意外的是，在RGB图像上进行分类，总体分类精度仅为39.38%。使用复现代码进行重建后的结果，对于地物分类效果，出人意料地低于RGB图像近10%。然而，在我们改进后的算法重建得到的结果中，比在RGB图像上的分类结果高出近2%。这个结果证明了我们改进的算法在评价指标上与复现代码相近，但在下游的分类任务中具有一定的优势。因此，我们强调了根据数据特性进行重建算法的改进和调整的重要性。

综上所述，通过优化和扩展我们的实验描述，我们清晰地呈现了在ICVL和DFC2018 Houston数据集上进行的比较实验的结果。我们的改进方法在光谱重建和下游分类任务中表现出一定的优势，这为进一步的研究和应用提供了有益的启示。

表 1. 在ICVL和DFC2018 Houston数据集中的定量结果

Dataset	Evaluation Index	UnGUN (Original)	UnGUN (复现)	UnGUN (新)
ICVL	PSNR	33.9775	34.2169	35.0162 ↑
	SSIM	0.9839	0.8812	0.9535 ↑
	SAM	4.9741	6.2048	5.5541 ↓
DFC2018 Houston	PSNR	28.5009	26.13	27.5946 ↑
	SSIM	0.8737	0.6555	0.7134 ↑
	SAM	21.0743	24.6587	23.3214 ↓

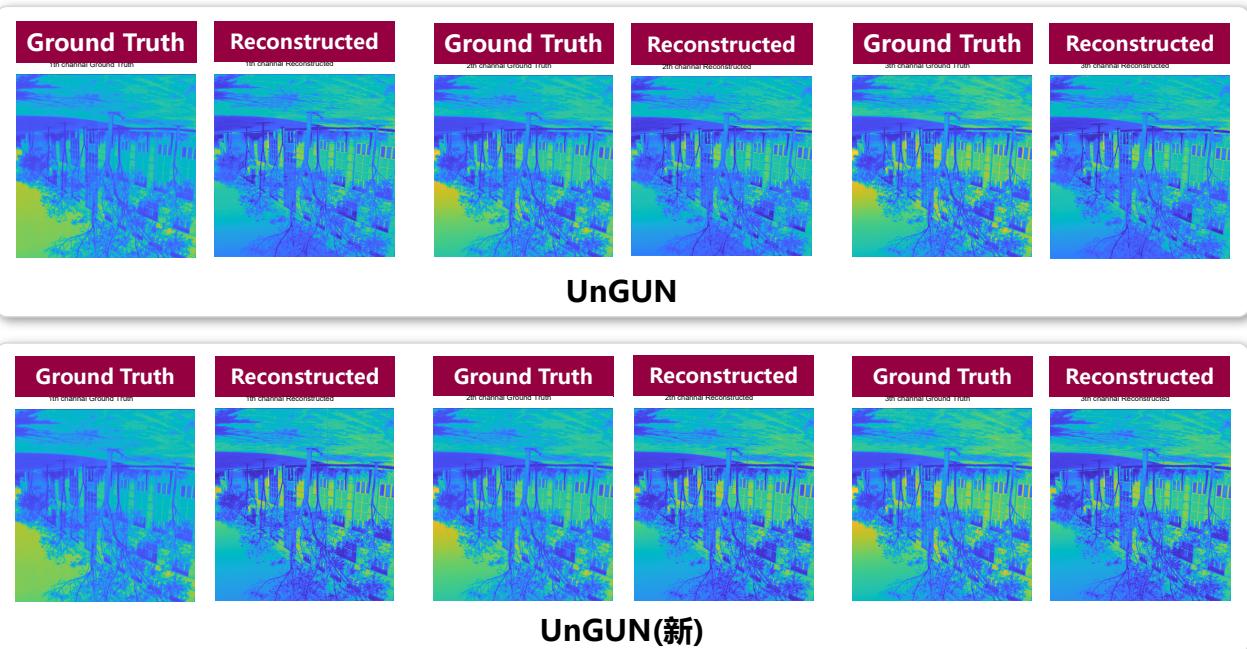


图 8. ICVL数据集实验结果

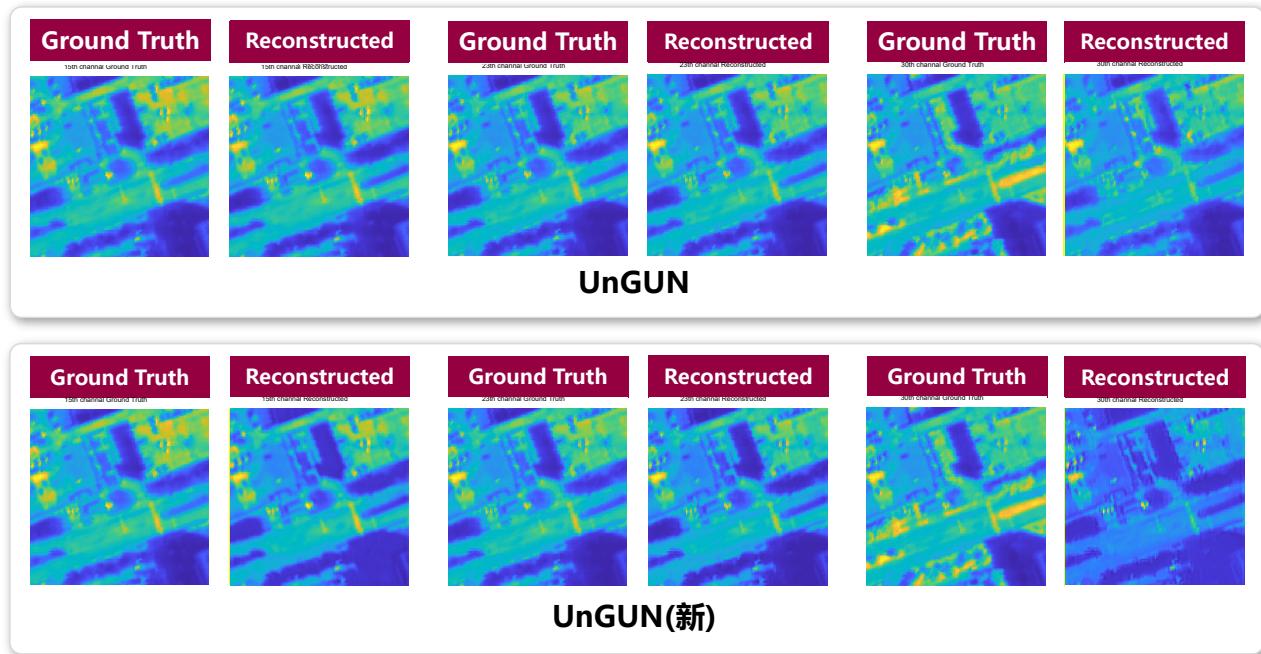


图 9. DFC2018 Houston数据集实验结果

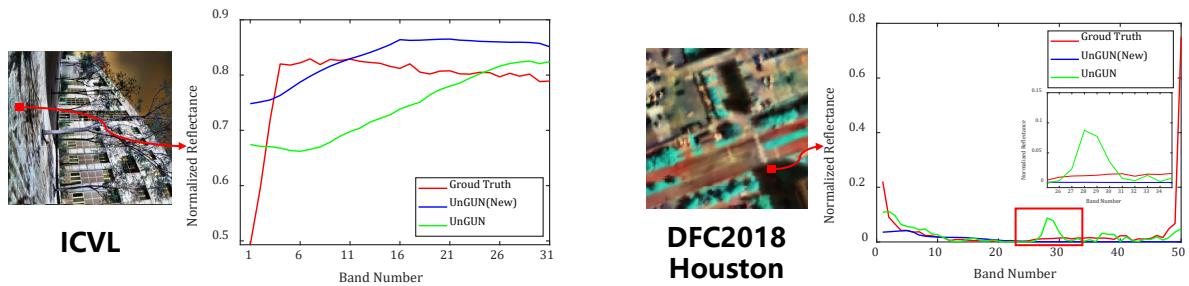


图 10. 在ICVL和DFC2018 Houston数据集上随机选点的光谱曲线

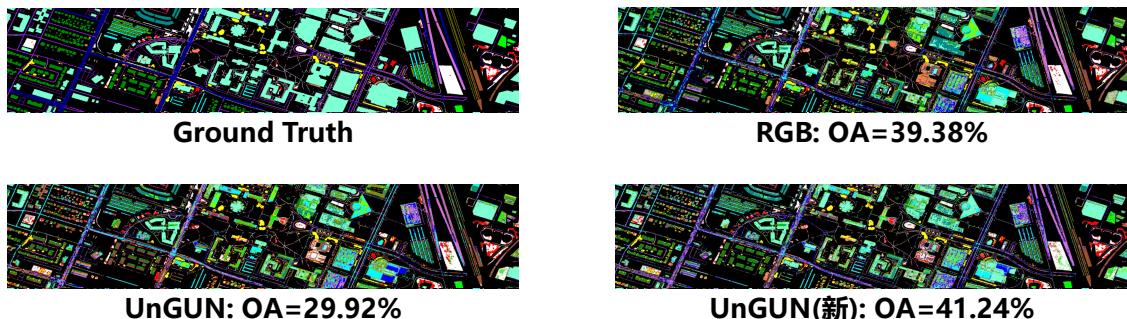


图 11. 在DFC2018 Houston数据集上对比重建结果应用于分类效果

## 6 总结与展望

本研究复现论文指出当前光谱超分辨率算法主要依赖于监督学习方法，但其面临着获取成对训练数据的困难。为应对这一难题，复现论文提出了一种名为UnGUN的解混合无监督光谱超分辨率框架，其旨在实现HSI重构，而无需依赖HSI-RGB图像的配对数据。该算法的核

心思想在于利用非配对HSI中地物的光谱特性和分布特征来引导RGB图像的光谱重建。具体而言，光谱特性通过从非配对HSI中学习图像元素来获得，而空间分布特性则直接从RGB图像中计算出丰度。然而，UnGUN在处理光谱邻近关系方面存在一定的不足之处，因此我们对其进行改进。

改进方法之一是对编码器进行了多尺度特征集成，这有助于降低计算复杂度。另外，我们从MAE中获得了启示，该方法将输入图像分割为小块并屏蔽随机小块，从而实现缺失像素的重建并减少数据冗余。最后，我们构建了一个新的损失函数，用于重建粗粒度的光谱-空间先验高光谱图像，并对其进行了细化处理。实验证明，这些改进使得我们的方法在卫星遥感数据集上表现优于原始方法，但在自然影像数据集上仍有改进空间。

未来的研究工作将集中于利用不同类型卫星所拍摄的遥感图像，并通过融合多源数据的特性来实现更高效的光谱重构。这将进一步提升光谱超分辨率的性能和应用领域。此外，我们还将探索新的技术手段和方法，以解决光谱邻近关系的挑战，并提高光谱重建的准确性和稳定性。

## 参考文献

- [1] Leyuan Fang, Shutao Li, Wuhui Duan, Jinchang Ren, and Jón Atli Benediktsson. Classification of hyperspectral images by exploiting spectral–spatial information of superpixel via multiple kernels. *IEEE Tran. Geosci. Remote Sens.*, 53(12):6663–6674, 2015.
- [2] Qi Wang, Wei Huang, Zhitong Xiong, and Xuelong Li. Looking closer at the scene: Multiscale representation learning for remote sensing image scene classification. *IEEE Trans. Neural Netw. Learn. Sys.*, 33(4):1414–1428, 2020.
- [3] Leyuan Fang, Nanjun He, Shutao Li, Pedram Ghamisi, and Jon Atli Benediktsson. Extinction profiles fusion for hyperspectral images classification. *IEEE Tran. Geosci. Remote Sens.*, 56(3):1803–1815, 2017.
- [4] Zhengxia Zou and Zhenwei Shi. Hierarchical suppression method for hyperspectral target detection. *IEEE Tran. Geosci. Remote Sens.*, 54(1):330–342, 2015.
- [5] Konstantinos Makantasis, Konstantinos Karantzalos, Anastasios Doulamis, and Konstantinos Loupos. Deep learning-based man-made object detection from hyperspectral data. In *Advances in Visual Computing: 11th International Symposium, ISVC 2015, Las Vegas, NV, USA, December 14–16, 2015, Proceedings, Part I* 11, pages 717–727. Springer, 2015.
- [6] Peng Ren, Min Xu, Yunhua Yu, Fang Chen, Xiangyuan Jiang, and Erfu Yang. Energy minimization with one dot fuzzy initialization for marine oil spill segmentation. *IEEE J. Ocean. Eng.*, 44(4):1102–1115, 2018.
- [7] Toygar Akgun, Yucel Altunbasak, and Russell M Mersereau. Super-resolution reconstruction of hyperspectral images. *IEEE Trans. Image Process.*, 14(11):1860–1875, 2005.

- [8] Shuiping Gou, Shuzhen Liu, Shuyuan Yang, and Licheng Jiao. Remote sensing image super-resolution reconstruction based on nonlocal pairwise dictionaries and double regularization. *IEEE J. Sel. Topics Appl. Earth Observ. Remote Sens.*, 7(12):4784–4792, 2014.
- [9] Hasan Irmak, Gozde Bozdagi Akar, and Seniha Esen Yuksel. A map-based approach for hyperspectral imagery super-resolution. *IEEE Trans. Image Process.*, 27(6):2942–2951, 2018.
- [10] Xinya Wang, Jiayi Ma, and Junjun Jiang. Hyperspectral image super-resolution via recurrent feedback embedding and spatial-spectral consistency regularization. *IEEE Transactions on Geoscience and Remote Sensing*, 60:1–13, 2021.
- [11] Manu Parmar, Steven Lansel, and Brian A. Wandell. Spatio-spectral reconstruction of the multispectral datacube using sparse recovery. *2008 15th IEEE International Conference on Image Processing*, pages 473–476, 2008.
- [12] Boaz Arad and Ohad Ben-Shahar. Sparse recovery of hyperspectral signal from natural rgb images. In *European Conference on Computer Vision*, 2016.
- [13] Qiaoying Qu, Bin Pan, Xia Xu, Tao Li, and Zhenwei Shi. Unmixing guided unsupervised network for rgb spectral super-resolution. *IEEE Trans. Image Process.*, 2023.
- [14] Zhiwei Xiong, Zhan Shi, Huiqun Li, Lizhi Wang, Dong Liu, and Feng Wu. Hscnn: Cnn-based hyperspectral image recovery from spectrally undersampled projections. *2017 IEEE International Conference on Computer Vision Workshops (ICCVW)*, pages 518–525, 2017.
- [15] Zhan Shi, Chang Wen Chen, Zhiwei Xiong, Dong Liu, and Feng Wu. Hscnn+: Advanced cnn-based hyperspectral recovery from rgb images. *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pages 1052–10528, 2018.
- [16] Lei Zhang, Zhiqiang Lang, Peng Wang, Wei Wei, Shengcai Liao, Ling Shao, and Yanning Zhang. Pixel-aware deep function-mixture network for spectral super-resolution. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 34, pages 12821–12828, 2020.
- [17] Silvano Galliani, Charis Lanaras, Dimitrios Marmanis, Emmanuel Baltsavias, and Konrad Schindler. Learned spectral super-resolution. *arXiv preprint arXiv:1703.09470*, 2017.
- [18] Ziyi Meng, Jiawei Ma, and Xin Yuan. End-to-end low cost compressive spectral imaging with spatial-spectral self-attention. In *Proc. Euro. Conf. on Computer Vision*, 2020.
- [19] Bing Tu, Qi Ren, Jun Li, Zhaolou Cao, Yunyun Chen, and Antonio J. Plaza. Ncglf2: Network combining global and local features for fusion of multisource remote sensing data. *Inf. Fusion*, 2023.